

# Atividade Prática em Sala de Aula

Gabriel Rodrigues

2025-11-05

Atividade Prática realizada no dia 05/11/2025, na disciplina de “Filogenia Molecular”, ministrada pelo Prof. Marco A. Costa, na Universidade Estadual de Santa Cruz (UESC) pelo Programa de Pós-Graduação em Genética e Biologia Molecular.

## Atividade

Editar as sequências contidas nos eletroferogramas anexos, gerando um arquivo word com as sequências Forward e Reverse, e as sequências consenso. Verificar qual espécie no banco de dados do NCBI apresenta maior identidade com cada sequência consenso obtida.

## Metodologia

A atividade deveria ser realizada a partir do software [BioEdit](#), entretanto não foi possível encontrar binários do software que fossem suportados pelo sistema operacional Linux (Archimux), que atualmente está sendo utilizado pelo discente.

Para contornar a situação, serão adotadas estratégias de processamento para processar os dados resultantes do sequenciamento Sanger (eletroferograma), que sigam os mesmos passos do tutorial apresentado em sala de aula.

## Análise dos arquivos .ab1

Arquivos *.ab1* são dados brutos vindos de sequenciadores tipo Sanger. Esses arquivos possuem a sequência do DNA analisada, um eletroferograma (um gráfico mostrando os picos de fluorescência para cada base) e uma pontuação de qualidade associada à cada base da sequência.

Nesse caso vamos utilizar o software [CutePeaks](#) para realizar o *basecalling*, a chamada das bases individuais da sequência analisada, para conferir seu pico de fluorescência e sua qualidade.



Figure 1: Exemplo de arquivo .ab1 lido pelo software CutePeaks

### Conversão de .ab1 para .fastq

Como não será possível trabalhar diretamente com o software *BioEdit*, será necessário realizar a conversão dos arquivos arquivos *.ab1* para o formato *.fastq*, formato padrão dos dados brutos de sequenciadores de nova geração, como os da plataforma *Illumina*.

Para realizar essa conversão, foi utilizada a biblioteca BioPython (suportada pela linguagem de programação Python) para criar o arquivo *abi2fastq.py* com o seguinte código:

```
# Importando a biblioteca BioPython
from Bio import SeqIO
import sys

# Definindo a entrada e a saída dos arquivos
entrada = sys.argv[1]
saída = sys.argv[2]

# Realizando a conversão dos dados
records = SeqIO.parse(entrada, "abi")
count = SeqIO.write(records, saída, "fastq")
```

O arquivo `abi2fastq.py` pode ser utilizado para inserir os dois argumentos para a conversão, o nome do arquivo de entrada e o nome do arquivo de saída (que será a conversão). Para rodar o código e realizar a conversão, executa-se no terminal linux:

```
python abi2fastq.py COC_2F.ab1 COC_2F.fastq
```

Com isso teremos nosso arquivo `.ab1` convertido para formato `.fastq`, seguindo essa estrutura:

Onde o identificador da sequência é o @13F e a pontuação *Phred* de qualidade está localizada abaixo do símbolo de +. Em termos práticos esse arquivo informa a sequência e a qualidade das bases, mas diferente do formato anterior, os picos de fluorescência não são informados.

## Checagem da qualidade dos arquivos fastq

Para checar se a conversão foi realizada corretamente, os arquivos de qualidade das sequências *.fastq* foram comparadas com a qualidade exibida no eletroferograma e checada no *CutePeaks*. Essa checagem foi realizada com o software [FastQC](#).




Figure 2: Qualidade do eletroferograma do arquivo RBA\_2R no software CutePeaks, a qualidade é representada pelas barras cinzas




Figure 3: Checagem de qualidade do arquivo fastq (RBA\_2R), através do software FastQC

### Remoção das bases de baixa qualidade

Para a remoção das bases de baixa qualidade foi utilizado o software [Seqtk](#), em sua função `trimfq`, que remove automaticamente as sequências de baixa qualidade ( $Phred < 15$ ) e bases não definidas.

As análises de qualidade também foram realizadas nas sequências após a remoção das bases de baixa qualidade.

## Conversão de FASTQ para FASTA

Após a trimagem das sequências e remoção de bases de não definidas, os arquivos *FASTQ* foram convertidos para o formato *FASTA* através da biblioteca **BioPython**, seguindo a mesma lógica da conversão dos arquivos *.ab1*:

```
# Importando a biblioteca BioPython
from Bio import SeqIO
import sys

# Definindo a entrada e a saída dos arquivos
entrada = sys.argv[1]
saída = sys.argv[2]

# Realizando a conversão dos dados
records = SeqIO.parse(entrada, "fastq")
count = SeqIO.write(records, saída, "fasta")
```

O arquivo final *fastq2fasta.py* então é chamado no terminal linux:

```
python fastq2fasta.py COC_2F.fastq COC_2F.fasta
```

Um arquivo em formato FASTA se assemelha à um arquivo FASTQ, porém sem os índices de qualidade por base (*Phred Score*) anexados ao arquivo das sequências. Outra diferença são os símbolos adotados, o *header* de uma sequência (seu cabeçalho) agora é marcado pelo símbolo > antes do nome da sequência.

## Obtenção da Sequência Consenso

A sequência consenso é o resultado da união via sobreposição das sequências *forward* e *reverse* do sequenciamento. Para fazer a montagem dessas sequências em uma única final. Para isso pode-se utilizar o software **CAP3**, que alinha a sobreposição das sequências para estabelecer as contigs finais, uma técnica denominada de *Overlap Layout Consensus*.

A entrada para o software CAP3 foi um arquivo FASTA com a junção das duas sequências (*forward* e *reverse*) de cada amostra, dessa maneira (Arquivo **COC\_merge.fasta**):

>13F

TTTATATTTAATTTACCAAGGATTGGACTAATTCACAAATTATTATAAATGAAAGAG  
GAAAAAAGGAAATTTGGAAATTAAAGAATAATTATGCTATATTAGGAATTGGATTT  
TAGGATTTATTGTATGAGCTCATCATATTACTGTAGGATTAGATGTTGATACCGAG  
CATATTACATCTGCAACAATAATTATTGCAATTCCACAGGAATTAAAGTTTAGAT  
GATTAGCAACTTATCATGGATCAAATTAAATTAAATTTAATATTTCATTTATGATCAATTG  
GATTATTTAATATTACTATTGGAGGATTAACAGGAATTATATTCAAATTCA  
TTGATATTATTTACATGATTCTATTACGTAGTTGGCATTTCACTATGTATTATCTA  
TAGGAGCAGTATTCATTGCAAGATTTCATTGATTTCCATTATCAGGAT  
TAATAATTAATCAAAATGATTAACATTCAATTTTTTATATTCAATTGGAATTAAATT  
TCACCTTTCTCAACATTAGGATTAATATC

>13R

AAAAAAAAATTGAAATTAAATCATTGATTAATTATTAAATCCTGATAATAAGGGAAA  
TCAATGAATAATCTGCAATAATGGAAAATCTGCTCTATAGATAATACATAGTGAAA  
ATGACCAACTACGTAAATAAGAATCATGTAATGATAATTCAATTGATGAATTGATAATAT  
AATTCCGTAAATCCTCCAATAGTAAATATTAAATAAATCCAATTGATCATATAATGA  
AATATTAAATTAATTGATCCATGATAAGTTGCTAATCATCTAAACTTAATTCC  
TGTAGGAATTGCAATAATTATTGTTGCAGATGTAATGCTCGTGTATCAACATCTAA  
TCCTACAGTAAATATGATGAGCTCATACAATAATCCTAAATCCAATTCTAATAT  
AGCATAAAATTATTCTAAATTCCAAAATTCCCTTTCTCTTCATTATAATAAT  
TTGTGAAATTAGTCAAATCCTGGTAAATTAAATATAAACCTCTGGATGACCAAAAAA  
TCAAAATAATGTTGATAA

## Alinhamento das sequências

As sequências finais foram Alinhadas via [BLASTn online](#) contra o banco de dados `core_nt`, uma versão reduzida e clusterizada do banco total de nucleotídeos `nt`.

## Resultados

### Qualidade das Sequências

A qualidade sequências dos arquivos *FASTQ* foram realizadas com o software **FastQC** e depois agragadas com o software **MultiQC**. As qualidades foram medidas antes e depois da remoção de sequências de baixa qualidade.




Figure 4: Qualidade das sequências SEM a remoção das bases de baixa qualidade




Figure 5: Qualidade das sequências COM a remoção das bases de baixa qualidade

## Sequências montadas

As sequências fasta (*forward* e *reverse*) foram unidas em arquivos únicos para cada código e amostra, **COC\_merged.fasta**; **MAC\_merged.fasta** e **RBA\_merged.fasta**. Esses arquivos foram montados utilizando o software CAP3 e tiveram como resultado final os seguintes tamanhos em bases:

Table 1: Tamanho das sequências em nucleotídeos

Amostra	Tamanho (nt)
COC	615
MAC	607
RBA	617

Como resultado da montagem, temos o arquivo FASTA final para cada sequência:

```
>COC
TTATCAACATTTATTTGATTTGGTCATCCAGAACGTTATTTAATTTACCAGG
ATTTGGACTAATTCAAAATTATTATAAAATGAAAGAGGAAAAAGGAAATTTGGAAA
TTAAGAATAATTCTGCTATATTAGGAATTGGATTTAGGATTATTGTATGAGCTCA
TCATATATTTACTGTAGGATTAGATGTTGATACACGAGCATATTTACATCTGCAACAAT
AATTATTGCAATTCTACAGGAATTAAAGTTTAGATGATTAGCAACTTATCATGGATC
AAAATTAATTAAATTAAATATTCATTATGATCAATTGGATTTATTTAATATTTACTAT
TGGAGGATTAACAGGAATTATATTCAAATTCAATTGATATTATTTACATGATT
TTATTACGTAGTGGTCATTTCACTATGTATTCTATAGGAGCAGTATTTCCATTAT
TGCAAGATTTATTCAATTGATTTCCATTATCAGGATTAATAATTAAATCAAAATGATT
AAAATTCATTTTTTATATTCAATTGGAATTAAATTCACTTTTCCCTAACATT
TTAGGATTAATATC

>RBA
TTATCAACATTTATTTGATTTGGTCATCCAGAACGTTATTTAATTTACCAGG
ATTTGGACTAATTCAAAATTATTATAAAATGAAAGAGGAAAAAGGAAATTTGGAAA
TTAAGAATAATTCTGCTATATTAGGAATTGGATTTAGGATTATTGTATGAGCTCA
TCATATATTTACTGTAGGATTAGATGTTGATACACGAGCATATTTACATCTGCAACAAT
AATTATTGCAATTCTACAGGAATTAAAGTTTAGATGATTAGCAACTTATCATGGATC
AAAATTAATTAAATATTCATTATGATCAATTGGATTTATTTAATATTTACTAT
TGGAGGATTAACAGGAATTATATTCAAATTCAATTGATATTCTACATGATT
TTATTACGTAGTGGTCATTTCACTATGTATTCTATAGGAGCAGTATTTCCATTAT
TGCAAGATTTATTCAATTGATTTCCATTATCAGTGAATTAAATTAAATCAAAATGAT
AAAATTCATTTTTTATATTCAATTGGAATTAAATTCACTTTTCCCTAACATT
TTTAGG
```

```
>MAC
TTATCACACATTATTTGATTTGGTCATCCAGAAGTTATTTAACCTTACAGG
ATTTGGACTAATTCAAAATTATTATAAATGAAAGAGGAAAAAGGAAATTTGGAAA
TTAAGAATAATTATGCTATATTAGGAATTGGATTTAGGATTATTGTATGAGCTCA
TCATATATTACTGTAGGATTAGATGTTGATACCGAGCATATTTACATCTGCAACAAT
AATTATTGCAATTCTACAGGAATTAAAGTTTAGATGATTAGCAACTTATCATGGATC
AAAATTAAATTAAATTTCATTATGATCAATTGGATTATTTAATATTACTAT
TGGAGGATTAACAGGAATTATATTCAAATTCAATTGATATTATTTACATGATT
TTATTACGTAGTTGGTCATTTCACTATGTATTATCTATAGGAGCAGTATTTCCATTAT
TGCAAGATTATTCAATTGATTTCCATTATTCAGGATTAATAATTAAATCAAAATGATT
AAAATTCAATTTTTTATATTCAATTGGAATTAAATTCACTTTTCCCTAACATT
TTAGGATTAAATATCA
```

## Alinhamento no BLAST

Foi realizado o alinhamento global das sequências em um banco de dados de nucleotídeos (*NCBI Core NT*), os resultados foram os seguintes:

Table 2: Melhores resultados do alinhamento no BLAST para cada amostra

Amostra	Melhor Hit	Organismo
COC	H2 cytochrome c oxidase subunit I (COI) gene	<i>Partamona rustica</i>
MAC	H2 cytochrome c oxidase subunit I (COI) gene	<i>Partamona rustica</i>
RBA	H5 cytochrome c oxidase subunit I (COI) gene	<i>Partamona rustica</i>

Os alinhamentos tiveram índices de identidade e cobertura maiores que 99% para os melhores alinhamentos.

As sequências aparentam ser derivadas da espécie *Partamona rustica*, especificamente vindas de subunidades H do gene **citocromo c oxidase**, sendo uma enzima na cadeia respiratória de transporte de elétrons das células.